

Posibles proyectos ALNAE

1 Estimación de Densidades mediante Series Ortogonales

La estimación no paramétrica de densidades busca reconstruir la función de densidad de una variable aleatoria absolutamente continua, a partir de observaciones sin asumir una forma paramétrica fija, el método clásico para eso es la estimación por funciones núcleo. Este otro enfoque utiliza otras herramientas que vimos en el curso: proyecta la función de densidad desconocida f sobre un subespacio de Hilbert de dimensión finita utilizando una base ortonormal en L^2 , y lo que se estiman son las coordenadas de la proyección en esa base.

Sea $f \in L^2(\mathbb{R})$ la función de densidad de una variable aleatoria X y $\{\phi_j\}_{j=0}^\infty$ una base ortonormal de L^2 (la base de Fourier, por ejemplo). La función f se puede representar como:

$$f(x) = \sum_{j=0}^{\infty} c_j \phi_j(x), \quad \text{donde} \quad c_j = \langle f, \phi_j \rangle_{L^2} = \int_{\mathbb{R}} f(x) \phi_j(x) dx = \mathbb{E}(\phi_j(X)). \quad (1)$$

Estimar f , se puede reducir a estimar los coeficientes c_j . Dada una muestra i.i.d. $\{X_i\}_{i=1}^n \sim f$, los coeficientes c_j se pueden estimar mediante promedios:

$$\hat{c}_j = \frac{1}{n} \sum_{i=1}^n \phi_j(X_i). \quad (2)$$

El estimador de f se obtiene entonces reemplazando los coeficientes teóricos por su versión estimada y truncando la representación a una base finita. El objetivo es entender este estimador, ver por qué es consistente, implementarlo computacionalmente y mostrar algunos ejemplos. Curiosidad: el histograma se puede ver como un caso muy particular de este estimador.

Referencias: ...

2 Teorema de Karhunen-Loève y su Aplicación a Datos Funcionales (FDA)

El Análisis de Datos Funcionales es la rama de la estadística que trata con observaciones que se modelan como funciones continuas en lugar de vectores de dimensión finita. El Teorema de Karhunen-Loève (KL) es la extensión infinito-dimensional del Análisis de Componentes Principales (PCA), permitiendo descomponer un dato funcional continuo utilizando las funciones propias del operador de covarianza del propio proceso.

Sea $X(t)$ un dato funcional (proceso estocástico) en $L^2([a, b])$ con media $\mu(t) = 0$ y función de autocovarianza continua $K(s, t) = \text{Cov}(X(s), X(t))$. El teorema establece que:

$$X(t) = \sum_{k=1}^{\infty} \xi_k \phi_k(t) \quad (3)$$

donde las variables aleatorias ξ_k no están correlacionadas y poseen varianza λ_k , mientras que $\{\phi_k(t)\}$ son las funciones propias del operador de covarianza. Esto es que resuelven la ecuación:

$$\lambda_k \phi_k(t) = \langle K(\cdot, t), \phi_k \rangle_{L^2([a, b])} = \int_a^b K(s, t) \phi_k(s) ds. \quad (4)$$

Referencias: ...

3 Wavelets vs Fourier para describir series de tiempo y su estacionalidad

La Transformada de Fourier permite escribir una función periódica, supongamos que $f \in L^2([0, 1])$, como suma de senos y cosenos, esto es nuevamente, un cambio de base en L^2 . Esto es:

$$f(t) = \frac{a_0}{2} + \sum_{n=1}^{\infty} (a_n \cos(2\pi nt) + b_n \sin(2\pi nt)) \quad (5)$$

donde los coeficientes de Fourier representan las coordenadas de la proyección de la función en esa base:

$$a_n = 2 \int_0^1 f(t) \cos(2\pi nt) dt \quad \text{y} \quad b_n = 2 \int_0^1 f(t) \sin(2\pi nt) dt \quad (6)$$

Cada seno y coseno dan información acerca de una frecuencia en particular (la frecuencia “ $2\pi n$ ”), por tanto el coeficiente que los multiplica da información de cuán importante es esa frecuencia en la serie. Esto se usa mucho en series de tiempo y tratamiento de señales. Lo que ocurre es que se necesita que la serie sea estacionaria (no confundir estacionariedad con estacionalidad), *grossomodo*, que sus propiedades estadísticas no cambien a lo largo del tiempo.

A diferencia de la Transformada de Fourier estándar, que destruye la localización temporal al representar la función en el dominio de las frecuencias, la transformada Wavelet proporciona una descomposición de tiempo-frecuencia que cuando ocurren cambios en las frecuencias da información acerca de la localización del cambio. Esto da una forma sencilla y directa de analizar series temporales no estacionarias, algo que no se puede hacer mediante la transformada de Fourier.

Referencias: ...

4 Clustering Espectral

Los algoritmos clásicos de clustering (como k -medias) fallan si las agrupaciones del conjunto de datos presentan geometrías complejas no esféricas ni linealmente separables. El clustering espectral soluciona esto interpretando los datos como nodos de un grafo y analizando el espectro (valores y vectores propios) de su matriz de adyacencia o de su Laplaciana, para representar los datos en un espacio de dimensión menor y hacer el ejercicio de clustering allí.

Referencias: ...

5 El problema del clique implantado

Un grafo aleatorio masivo de Erdős-Rényi $G(n, p)$ es el modelo más sencillo de grafo aleatorio, cada posible arista del grafo ocurre o no según una variable con distribución de Bernoulli(p) y hay independencia entre los sorteos de las aristas.

Supongamos que tenemos un grafo $G(n, 1/2)$. Ahora se elige un subconjunto de nodos, de tamaño k , y en ese subconjunto se planta un clique (un subgrafo completo, todos los nodos están conectados entre sí).

El objetivo del problema, es dado un grafo, detectar si alguien implantó el clique o no. La dificultad del problema depende del valor de k (el tamaño del subgrafo implantado). Si k es muy chico, puede ser como encontrar una aguja en un pajar: el grafo $G(n, 1/2)$ naturalmente va a generar cliques de tamaño k . Por el contrario si k es muy grande, el clique es algo sería algo tan raro que se puede detectar en seguida. El asunto es detectarlo para un rango de valores de k . Hay un algoritmo para la detección basado en los vectores propios de la matriz de adyacencia del grafo.

Referencias: ...

6 Detección de comunidades mediante Stochastic Block Model (SBM)

La detección de comunidades es una versión del problema de clustering para datos en redes. El objetivo es agrupar los nodos de un grafo en conjuntos que tengan una alta densidad de conexiones internas y una baja densidad de conexiones entre distintas comunidades.

SBM es un modelo generativo de grafos aleatorios que generaliza el modelo de Erdős-Rényi. Sea $V = \{1, 2, \dots, n\}$ el conjunto de vértices de un grafo y sea k el número de comunidades. Cada nodo $i \in V$ se asigna de forma independiente a una de las k comunidades latentes según una distribución de probabilidad dada por el vector de proporciones $\boldsymbol{\pi} = (\pi_1, \pi_2, \dots, \pi_k)$, donde π_r representa la probabilidad de que un nodo pertenezca a la comunidad r , satisfaciendo que $\sum_{r=1}^k \pi_r = 1$. Definimos la variable latente $\sigma_i \in \{1, 2, \dots, k\}$ como la etiqueta de la comunidad a la que pertenece el nodo i .

Las aristas de la matriz de adyacencia $\mathbf{A} \in \{0, 1\}^{n \times n}$ se generan de forma independiente mediante variables de Bernoulli cuyas probabilidades están determinadas por una matriz de conectividad entre bloques $\mathbf{B} \in [0, 1]^{k \times k}$. Así, la entrada B_{rs} representa la probabilidad de enlace entre un nodo de la comunidad r y un nodo de la comunidad s :

$$P(A_{ij} = 1) = B_{\sigma_i \sigma_j} \quad (7)$$

Para formular el comportamiento estadístico del grafo, definimos la matriz de asignación $\mathbf{Z} \in \{0, 1\}^{n \times k}$, donde cada fila contiene un único uno que indica a qué comunidad pertenece, es decir, la entrada $Z_{ir} = 1$ si $\sigma_i = r$ y $Z_{ir} = 0$ en caso contrario. De este modo, la matriz esperada $\bar{\mathbf{A}} = \mathbb{E}[\mathbf{A}]$ se puede descomponer de forma exacta como una estructura de rango a lo sumo k :

$$\bar{\mathbf{A}} = \mathbf{Z}\mathbf{B}\mathbf{Z}^\top.$$

El problema estadístico es estimar las comunidades, a partir de observar el grafo.

Referencias: ...

7 Completado de matrices y el problema de recomendación de Netflix

Los sistemas de recomendación modelan el problema mediante matrices de usuarios vs. películas (usando como ejemplo el de un sistema para recomendar películas), donde la entrada (i, j) contiene la valoración que tiene el usuario i sobre la película j . Estas matrices tienen una muy baja cantidad de celdas observadas, porque los usuarios vieron una cantidad limitada de películas. El completado de matrices asume que esa matriz es de rango bajo, y busca inferir esas entradas faltantes.

Sea $\mathbf{M} \in \mathbb{R}^{m \times n}$ la matriz original de rango bajo y Ω el conjunto de índices observados. El problema matemático no convexo se relaja a una optimización convexa minimizando la Norma Nuclear $\|\mathbf{X}\|_*$ (la suma de sus valores singulares):

$$\min_{\mathbf{X} \in \mathbb{R}^{m \times n}} \|\mathbf{X}\|_* \quad \text{sujeto a} \quad P_{\Omega}(\mathbf{X}) = P_{\Omega}(\mathbf{M}) \quad (8)$$

Este problema de optimización se resuelve mediante un algoritmo iterativo que va comprimiendo los valores singulares. En cada iteración se aplica un operador de contracción sobre la descomposición en valores singulares de la matriz y como resultado se obtiene la matriz reconstruida.

Referencias: ...